

Python ile Shodan Verilerinin Toplanması, Analizi ve Görselleştirilmesi

İnternete bağlı milyonlarca cihazın güvenlik açıklarını otomatik olarak tespit eden, yapay zeka destekli bir siber tehdit analiz platformu.

YUSUF BARUT-2355090

ADLI BİLİŞİM MÜHENDİSLİĞİ

PYTHON • AI • WEB SCRAPING

Problem ve Proje Amacı

HEDEFLER & KAPSAM

Modern internet altyapısında milyonlarca cihaz ve servis internete açık şekilde çalışmaktadır. Bu servisler; port numaraları, servis türleri ve coğrafi konum bilgileriyle birlikte çeşitli platformlar üzerinden analiz edilebilmektedir. Bu kadar büyük ölçekteki verilerin manuel olarak incelenmesi oldukça zor ve zaman alıcıdır.

Bu projede, Shodan API kullanılarak farklı ülkelerdeki açık servis verileri Python programlama dili ile otomatik olarak çekilmiş ve analiz edilmiştir. Çekilen veriler temizlenmiş, düzenlenmiş ve görselleştirilerek anlamlı sonuçlar elde edilmiştir.

Projenin temel amacı:

- Python ile otomatik veri toplama süreçlerini uygulamak
- Büyük veri kümelerini analiz etmek
- Verileri görselleştirmek
- Yapay zeka algoritmaları ile risk sınıflandırması gerçekleştirmek
- İnteraktif bir dashboard geliştirmektir

Bu çalışma sayesinde web scraping, veri temizleme, veri analizi, yapay zeka ve görselleştirme süreçleri tek bir proje altında birleştirilmiştir.

Kullanılan Teknolojiler

TEKNOLOJİ STACK'İ

Proje, modern Python ekosisteminin en güçlü ve yaygın kullanılan kütüphanelerinden yararlanarak tasarlanmıştır. Her teknoloji, pipeline'ın belirli bir aşamasında kritik bir rol üstlenmektedir. Veri toplama katmanından görselleştirme katmanına kadar her bileşen, performans ve ölçeklenebilirlik göz önünde bulundurularak seçilmiştir. Aşağıdaki tablo, kullanılan teknolojilerin proje içindeki işlevlerini ve entegrasyon noktalarını özetlemektedir.

Teknoloji	Amaç	Kullanım Alanı
Python	Veri işleme ve otomasyon	Tüm pipeline'ın temel programlama dili
Requests	API istekleri	Shodan REST API ile HTTP iletişimi
Pandas	Veri analizi	CSV işleme, DataFrame manipülasyonu
Scikit-learn	AI modelleri	Anomali tespiti, risk sınıflandırması
Streamlit	Dashboard	İnteraktif web arayüzü ve raporlama
Plotly	İnteraktif grafik	Dinamik chart'lar ve harita görselleştirme
Seaborn	Heatmap	Isı haritası ve korelasyon matrisleri
Shodan API	Veri kaynağı	İnternet tarama ve servis keşfi

Python, projenin tüm katmanlarında birleştirici dil olarak kullanılmıştır. Requests kütüphanesi, Shodan API'sine yapılan HTTP GET isteklerini yönetmekte ve JSON yanıtlarını işlemektedir. Pandas, toplanan ham veriyi DataFrame yapısına dönüştürerek sıralama, filtreleme ve CSV export işlemlerini kolaylaştırmaktadır. Scikit-learn, anomali tespiti için makine öğrenmesi modelleri sağlamakta; özellikle denetimsiz öğrenme algoritmaları etiketsiz veride pattern bulmada etkili olmaktadır.

Streamlit, Python kodunu doğrudan interaktif web uygulamasına dönüştürme kapasitesiyle dashboard geliştirme sürecini önemli ölçüde hızlandırmaktadır. Plotly ve Seaborn ise veriyi görsel olarak anlamlı biçimde sunmak için tamamlayıcı roller üstlenmektedir — Plotly interaktif zoom ve filtreleme özellikleri sunarken, Seaborn istatistiksel görselleştirmelerde derinlik katmaktadır. Tüm bu teknolojiler birlikte çalışarak uçtan uca bir siber analiz pipeline'ı oluşturmaktadır.



Python Ekosistemi

Requests, Pandas ve Scikit-learn ile uçtan uca veri pipeline'ı



Görselleştirme

Plotly ve Seaborn ile interaktif grafikler ve ısı haritaları



Streamlit Dashboard

Gerçek zamanlı analiz ve raporlama arayüzü



Shodan API

Dünyanın en büyük internet tarama veritabanına erişim

Sistem Mimarisi


END-TO-END PIPELINE

Bu projenin en kritik bileşeni, veri toplamadan görselleştirmeye kadar uzanan kesintisiz ve otomatikleştirilmiş pipeline yapısıdır. Her aşama bir öncekinin çıktısını girdi olarak almakta ve bir sonraki aşamaya hazırlanmış veri üretmektedir. Bu mimari yaklaşım, sistemin modüler, genişletilebilir ve bakım kolaylığı yüksek olmasını sağlamaktadır. Pipeline'ın her katmanı bağımsız olarak test edilebilir ve geliştirilebilir yapıdadır.

Pipeline'ın ilk aşaması olan Shodan API entegrasyonu, çevre değişkenlerinden okunan API anahtarı ile kimlik doğrulama yaparak güvenli bir iletişim kanalı kurar. Python veri toplama modülü, önceden tanımlanmış ülke ve servis listelerini kullanarak sistematik sorgular oluşturur. Her sorgu için API yanıtı parse edilir, hata durumları yakalanır ve rate limiting kurallarına uyularak ardışık istekler gönderilir. Toplanan ham veriler CSV formatında diske yazılarak kalıcı hale getirilir.

Veri temizleme aşamasında, toplanan ham verideki eksik değerler, tekrarlar ve tutarsızlıklar giderilir. Pandas kütüphanesi kullanılarak veri normalizasyonu, sütun yeniden adlandırma ve tip dönüşümü işlemleri uygulanır. Temizlenmiş veri, AI analiz modülüne hazır hale getirilir. Bu modülde Scikit-learn algoritmaları devreye girer; Isolation Forest veya One-Class SVM gibi denetimsiz öğrenme yöntemleriyle normal davranış profillerinden sapmalar tespit edilir. Her kayıt için risk skoru hesaplanır ve sınıflandırma etiketi atanır.

Son aşama olan dashboard katmanında, Streamlit framework'ü analitik sonuçları kullanıcı dostu bir arayüzde sunar. Plotly grafikleri interaktif biçimde render edilir, Seaborn ısı haritaları ülke-servis matrisini görselleştirir ve kullanıcılar filtreleme ile detaylı keşif yapabilir. Tüm pipeline, tek bir komutla çalıştırılabilecek şekilde yapılandırılmıştır ve yeni ülke veya servis eklemek yalnızca konfigürasyon dosyasını güncellemeyi gerektirir.



Yukarıdaki pipeline diyagramı, sistemin altı temel aşamasını ve bu aşamalar arasındaki veri akışını özetlemektedir. Her aşama bir sonrakine girdi sağlayarak kesintisiz bir otomasyon zinciri oluşturmaktadır.

Pipeline'ın Güçlü Yönleri

- Her modül bağımsız test edilebilir
- Yeni ülke/servis eklemek kolaydır
- Hata toleranslı ve loglu yapı
- Gerçek zamanlı genişletilebilir
- Tekrarlanabilir ve otomatikleştirilmiş

Veri Akışı Özeti

Shodan API'den çekilen ham veriler, Python script'i tarafından işlenerek yapılandırılmış CSV dosyalarına dönüştürülür. Temizlenen veriler AI modellerine beslenir ve elde edilen risk skorları dashboard üzerinde görselleştirilir. Bu akış, manuel müdahale gerektirmeden tam otomatik çalışabilir.

Veri Toplama Süreci

KOD & IMPLEMENTASYON

Veri toplama süreci, projenin temelini oluşturan kritik bir aşamadır. Bu aşamada Shodan API kullanılarak 11 farklı ülkede (Türkiye, ABD, Almanya, Fransa, Rusya, Çin, İngiltere, Hollanda, Japonya, Hindistan ve Brezilya) 7 kritik servis kombinasyonu (SSH, RDP, FTP, SMB, MongoDB, Redis ve Elasticsearch) sistematik biçimde taranmaktadır. Toplamda 77 farklı sorgu kombinasyonu çalıştırılmakta ve her sorgunun sonucu yapılandırılmış bir veri setine dönüştürülmektedir.

Aşağıdaki kod bloğu, projenin veri toplama modülünün temel yapısını göstermektedir. Kod, önce ortam değişkenlerinden API anahtarını yükler, ardından tanımlı ülke ve servis listelerini kullanarak döngüsel biçimde API istekleri gönderir. Her başarılı yanıt parse edilerek sonuç listesine eklenir, hata durumlarında ise exception handling mekanizması devreye girer. Rate limiting ihlallerini önlemek amacıyla her istek arasında 1.2 saniyelik bekleme süresi uygulanmaktadır.

```
import requests
import pandas as pd
import time
import os
from dotenv import load_dotenv

# ENV YÜKLE
load_dotenv()
API_KEY = os.getenv("SHODAN_API_KEY")
if not API_KEY:
    raise ValueError("SHODAN_API_KEY bulunamadı!")

# ÜLKELER
countries = ["TR", "US", "DE", "FR", "RU",
             "CN", "GB", "NL", "JP", "IN", "BR"]

# SERVİSLER
services = ["port:22", "port:3389", "port:21",
            "port:445", "mongodb", "redis", "elasticsearch"]

# API
BASE_URL = "https://api.shodan.io/shodan/host/count"
results = []

# VERİ TOPLAMA
for country in countries:
    print(f"\n[ÜLKE] {country}")
    for service in services:
        query = f"{service} country:{country}"
        params = {"key": API_KEY, "query": query}
        try:
            response = requests.get(BASE_URL, params=params, timeout=15)
            response.raise_for_status()
            data = response.json()
            total = data.get("total", 0)
            results.append({
                "country": country,
                "service": service,
                "query": query,
                "total": total
            })
            print(f"[OK] {query:<35} -> {total}")
        except requests.exceptions.RequestException as e:
            print(f"[HATA] {query}")
            print(e)
            time.sleep(1.2) # Rate limit dostu bekleme

# DATAFRAME
df = pd.DataFrame(results)
df = df.sort_values(by="total", ascending=False)

# CSV KAYDET
df.to_csv("raw_data.csv", index=False)
print(f"\nVeri başarıyla kaydedildi: raw_data.csv")
print("\nİlk 10 kayıt:\n")
print(df.head(10))
```

Kodda dikkat çeken önemli tasarım kararları şunlardır: `query = f"{service} country:{country}"` satırı, Shodan'ın sorgu dilini kullanarak servis ve ülke filtrelerini birleştirmektedir. `response = requests.get(...)` çağrısı ise API'ye parametrelili istek göndermekte ve JSON yanıtını döndürmektedir. Country filtreleme sayesinde coğrafi bazlı analiz mümkün olurken, servis filtreleme kritik port ve servis tiplerini hedef almaktadır. Otomatik veri çekme süreci tamamen hands-free çalışmakta ve CSV kayıt mekanizması verinin kalıcı olarak saklanmasını güvence altına almaktadır.

Country Filtreleme

11 farklı ülke kodu kullanılarak coğrafi bazlı tarama yapılır. Her ülke için ayrı ayrı sorgu üretilir ve sonuçlar karşılaştırmalı analiz için saklanır.

Servis Filtreleme

SSH (22), RDP (3389), FTP (21), SMB (445), MongoDB, Redis ve Elasticsearch servisleri hedeflenir. Bu servisler en sık istismar edilen ve internete maruz kalan servislerdir.

Otomatik Veri Çekme

İç içe döngüler kullanılarak tüm ülke-servis kombinasyonları otomatik olarak taranır. Her iterasyonda API yanıtı parse edilir ve sonuçlar listeye eklenir.

CSV Kayıt & Veri Saklama

Tüm sonuçlar Pandas DataFrame'e dönüştürülür, toplam sayısına göre büyükten küçüğe sıralanır ve `raw_data.csv` dosyasına yazılır.

Hata Yönetimi & Rate Limiting

`try-except` blokları ile network hataları yakalanır. `time.sleep(1.2)` ile API rate limit kurallarına uyulur ve bağlantı kopmaları önlenir.

Veri Temizleme

KOD & IMPLEMENTASYON

Veri temizleme süreci, ham verinin analiz için hazırlanması aşamasıdır. Shodan API'sinden çekilen veriler eksik değerler, tutarsızlıklar ve hatalı formatlar içerebilir. Bu aşamada Pandas kütüphanesi kullanılarak veri normalizasyonu, eksik değer temizleme ve tip dönüşümü işlemleri uygulanır. Temizlenen veriler daha sonra pivot tablo yapısına dönüştürülerek ülke-servis matrisini oluşturur. Log scale dönüşümü ise geniş değer aralığını görselleştirmeye uygun hale getirir.

Aşağıdaki kod bloğu, veri temizleme ve risk modeli oluşturma sürecini göstermektedir:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# -----
# CSV OKU
# -----

df = pd.read_csv("raw_data.csv")

print("\nHAM VERİ:\n")
print(df.head())

# -----
# VERİ TEMİZLEME
# -----

df = df.dropna(subset=["total"])      # boş satırları sil
df = df[df["total"] >= 0]           # negatif değerleri kaldır
df["service"] = df["service"].str.strip() # boşluk temizle
df["country"] = df["country"].str.strip()
df["total"] = df["total"].astype(int)

print("\nTEMİZLENMİŞ VERİ:\n")
print(df.head())

# -----
# PIVOT TABLO
# -----

pivot = df.pivot(
    index="country",
    columns="service",
    values="total"
)

print("\nPIVOT TABLO:\n")
print(pivot)

# -----
# HEATMAP
# -----

plt.figure(figsize=(12, 6))

sns.heatmap(
    np.log10(pivot + 1),
    annot=True,
    cmap="Reds"
)

plt.title("Log-Scaled Global Exposure Heatmap")

plt.tight_layout()
plt.show()

# -----
# RISK MODELİ
# -----

risk_weights = {
    "port:22": 3,
    "port:3389": 5,
    "port:21": 4,
    "port:445": 5,
    "mongodb": 4,
    "redis": 4,
    "elasticsearch": 3
}

df["weight"] = (
    df["service"]
    .map(risk_weights)
    .fillna(1)
)

df["risk_score"] = df["total"] * df["weight"]

# -----
# ÜLKE BAZLI RISK
# -----

country_risk = (
    df.groupby("country")["risk_score"]
    .sum()
    .sort_values(ascending=False)
)

print("\nÜLKE RİSK SKORLARI:\n")
print(country_risk)

# -----
# BAR CHART
# -----

plt.figure(figsize=(10, 5))

country_risk.plot(kind="bar")


plt.title("Cyber Risk Index by Country")
plt.ylabel("Risk Score")

plt.tight_layout()
plt.show()
```

Yukarıdaki kod bloğu, ham Shodan verisini temizleme, dönüştürme ve risk skorlama için temel adımları göstermektedir. Bu


aşamalar, ham veriyi anlamlı içgörüler ve görselleştirmeler için hazır hale getirir.

Siber Risk Maruziyeti Isı Haritası



Yukarıdaki ısı haritası, farklı ülkelerdeki çeşitli internet servislerinin logaritmik ölçekteki maruziyetini göstermektedir. Koyu kırmızı renkler daha yüksek maruziyeti temsil ederken, açık renkler daha düşük maruziyeti göstermektedir. Bu görselleştirme, ülke ve servis bazında siber risk dağılımını hızlıca anlamamızı sağlar.

Ülke Bazlı Siber Risk Endeksi



Bu bar grafiği, her ülkenin toplam siber risk skorunu göstermektedir. Risk skorları, servislerin kritiklik seviyesine göre ağırlıklandırılmış ve her ülkenin internete açık cihaz sayısı ile çarpılarak elde edilmiştir. Grafikte, en yüksek siber risk maruziyetine sahip ülkelerden en düşüğüne doğru bir sıralama görülmektedir.

Eksik Veri Temizleme

`df.dropna(subset=["total"])` satırı, "total" sütununda boş değer içeren satırları kaldırır. `df[df["total"] >= 0]` ise negatif değerleri filtreleyerek veri bütünlüğünü sağlar.

Normalization

`df["service"].str.strip()` ve `df["country"].str.strip()` işlemleri, metin alanlarındaki başında ve sonundaki boşlukları temizler. `df["total"].astype(int)` ise sayısal değerleri tam sayıya dönüştürerek tutarlılık sağlar.

Pivot Tablo

`df.pivot()` fonksiyonu, uzun formattaki veriyi geniş formata dönüştürerek ülke-servis matrisini oluşturur.

Bu yapı, ülkeler arasında karşılaştırma yapmayı kolaylaştırır.

Log Scale

`np.log10(pivot + 1)` dönüşümü, geniş değer aralığını (0'dan milyonlara) logaritmik ölçeğe çekerek görselleştirmeyi daha anlamlı hale getirir. Küçük ve büyük değerler arasındaki fark daha net görülür.

Risk Modeli

Her servis için ağırlık (`weight`) tanımlanır. RDP (port 3389) ve SMB (port 445) gibi kritik servisler daha yüksek ağırlık alır. Risk skoru, toplam cihaz sayısı ile servis ağırlığının çarpımıyla hesaplanır: `risk_score = total × weight`

Ülke Bazlı Risk

`groupby("country")` ile her ülkenin tüm servisleri için toplam risk skoru hesaplanır ve yüksekten küçüğe sıralanır. Bu, hangi ülkelerin daha yüksek siber risk altında olduğunu gösterir.



KOD & IMPLEMENTASYON

Risk Modeli

Risk modeli, projenin en kritik bileşenidir. Her servisin internete maruz kalması, o servisin kritiklik seviyesine göre ağırlıklandırılarak siber risk skoruna dönüştürülür. Bu model, güvenlik ekiplerinin kaynakları en etkili şekilde dağıtmasını sağlar.

Risk Skoru Formülü:

$$\text{risk_score} = \text{total_exposed_devices} \times \text{risk_weight}$$

Her servis için tanımlanan risk ağırlıkları (risk_weight), o servisin istismar edilme kolaylığı, yaygın saldırı vektörleri ve potansiyel hasar seviyesine göre belirlenmiştir.

Servis Risk Ağırlıkları:

Servis	Port/Tür	Risk Ağırlığı	Tehdit Vektörü
RDP	3389	5	Ransomware, Brute Force, Lateral Movement
SMB	445	5	EternalBlue, Ransomware, Worm Propagation
FTP	21	4	Weak Authentication, Credential Stuffing
MongoDB	-	4	NoSQL Injection, Unauthorized Access
Redis	-	4	Memory Exploitation, Data Theft
SSH	22	3	Brute Force (düşük risk, güçlü auth)
Elasticsearch	-	3	Information Disclosure, Query Injection

Neden Bu Ağırlıklar?

RDP (Risk: 5)

Remote Desktop Protocol, saldırganlar için en değerli hedeflerden biridir. Brute Force saldırıları ile erişim sağlanan RDP oturumları, doğrudan ransomware dağıtımı, veri hırsızlığı ve ağ içinde yanal hareket (lateral movement) için kullanılır. 2017 WannaCry saldırısı gibi büyük ölçekli siber olaylar RDP üzerinden başlamıştır.

SMB (Risk: 5)

Server Message Block, Windows ağlarının omurgasıdır. EternalBlue gibi kritik açıklar SMB üzerinden istismar edilir. Bir kez erişim sağlandığında, saldırgan tüm ağa yayılabilir. Petya, NotPetya ve WannaCry gibi ünlü ransomware'lar SMB açıklarını kullanmıştır.

FTP (Risk: 4)

File Transfer Protocol, zayıf kimlik doğrulama mekanizmasıyla bilinir. Brute Force saldırıları başarılı olabilir ve FTP sunucusu ele geçirildiğinde, hassas dosyalara doğrudan erişim sağlanır. Eski sistemlerde hala yaygındır.

MongoDB & Redis (Risk: 4)

NoSQL veritabanları, yanlış yapılandırıldığında kimlik doğrulama olmadan erişime açık kalabilir. Milyonlarca kayıt içeren bu veritabanları ele geçirildiğinde, veri hırsızlığı ve fidye saldırıları meydana gelir.

SSH (Risk: 3)

Secure Shell, güçlü şifreleme ve kimlik doğrulama mekanizmasına sahiptir. Brute Force saldırıları mümkün olsa da, modern SSH yapılandırmaları (key-based auth) bu riski önemli ölçüde azaltır.

Elasticsearch (Risk: 3)

Arama ve analitik motoru, yanlış yapılandırıldığında sorgu enjeksiyonuna açık olabilir. Ancak doğrudan kod yürütme riski diğer servislerden daha düşüktür.

Kod Implementasyonu:

```
import pandas as pd

# CSV OKU
df = pd.read_csv("raw_data.csv")

# RISK AĞIRLIKLARI
risk_weights = {
    "port:22": 3,      # SSH
    "port:3389": 5,    # RDP
    "port:21": 4,      # FTP
    "port:445": 5,     # SMB
    "mongodb": 4,
    "redis": 4,
    "elasticsearch": 3
}

# RISK SCORE HESAPLA
df["risk_weight"] = df["service"].map(risk_weights)
df["risk_score"] = df["total"] * df["risk_weight"]

# ÜLKE BAZLI TOPLAM RISK
country_risk = (
    df.groupby("country")["risk_score"]
    .sum()
    .sort_values(ascending=False)
)

# SONUÇ
print("\nÜLKE RİSK SKORLARI:\n")
print(country_risk)

# CSV KAYDET
country_risk.to_csv("risk_scores.csv")
print("\nrisk_scores.csv oluşturuldu.")
```

Kodun Açıklaması:

01

Risk Ağırlıkları Tanımlama

risk_weights sözlüğü, her servis için kritiklik seviyesini belirler.

02

Ağırlık Eşleştirme

df["risk_weight"] = df["service"].map(risk_weights) satırı, her satırdaki servise karşılık gelen ağırlığı atar.

03

Risk Skoru Hesaplama

df["risk_score"] = df["total"] * df["risk_weight"] formülü, internete açık cihaz sayısını servisin kritiklik seviyesiyle çarpar.

04

Ülke Bazlı Toplama

groupby("country") ile her ülkenin tüm servisleri için toplam risk skoru hesaplanır.

05

Sıralama

sort_values(ascending=False) ile en yüksek riskli ülkeler başa gelir.

06

Kayıt

Sonuçlar risk_scores.csv dosyasına kaydedilir ve raporlama için kullanılır.



Global Siber Risk Haritası

Siber güvenlik verilerini coğrafi olarak görselleştirmek, tehdit dağılımlarını ve risk yoğunluklarını anlamak için kritik öneme sahiptir. Bu bölümde, internete açık servislerin neden olduğu siber riskin dünya haritası üzerinde nasıl interaktif bir şekilde görüntüleneceğini inceleyeceğiz. Plotly kloroilet haritaları kullanarak, ülkeler bazında toplanan risk skorlarını kolayca yorumlanabilir ve eyleme dönüştürülebilir bir formata dönüştürüyoruz.

Bu harita, güvenlik ekiplerinin küresel siber tehdit ortamını hızlıca kavramasına ve kaynaklarını en çok risk altındaki bölgelere odaklamasına olanak tanır.

Kod Implementasyonu: Plotly ile Harita Oluşturma

```
import pandas as pd
import plotly.express as px
import numpy as np

# CSV OKU
df = pd.read_csv("raw_data.csv")

# ISO2'den ISO3'e ülke kodlarını dönüştürme (Plotly için gerekli)
country_code_map = {
    "TR": "TUR", "US": "USA", "DE": "DEU", "FR": "FRA", "RU": "RUS",
    "CN": "CHN", "GB": "GBR", "NL": "NLD", "JP": "JPN", "IN": "IND",
    "BR": "BRA"
}
df["country_iso3"] = df["country"].map(country_code_map)

# Daha önceki adımda tanımlanan risk ağırlıklarını tekrar kullan
risk_weights = {
    "port:22": 3,      # SSH
    "port:3389": 5,    # RDP
    "port:21": 4,      # FTP
    "port:445": 5,     # SMB
    "mongodb": 4,
    "redis": 4,
    "elasticsearch": 3
}

# Servislere risk ağırlıklarını atama
df["risk_weight"] = df["service"].map(risk_weights)

# Toplam siber risk skorunu hesaplama
# 'total' sütunundaki NaN değerlerini 0 ile doldur ve int'e dönüştür
df["total"] = df["total"].fillna(0).astype(int)
df["risk_score"] = df["total"] * df["risk_weight"]

# Ülke bazında toplam risk skorunu hesapla
country_risk_scores = df.groupby("country_iso3")["risk_score"].sum().reset_index()
country_risk_scores.rename(columns={"risk_score": "total_risk_score"}, inplace=True)

# Görselleştirme için logaritmik ölçeklendirme (geniş aralıkları yönetmek için)
country_risk_scores["log_risk_score"] = np.log10(country_risk_scores["total_risk_score"] + 1)

# Plotly choropleth haritası oluşturma
fig = px.choropleth(
    country_risk_scores,
    locations="country_iso3",
    color="log_risk_score",
    hover_name="country_iso3", # Hover edildiğinde ülke adını göster
    hover_data={"total_risk_score": True, "log_risk_score": False}, # Hover'da risk skorunu göster
    color_continuous_scale=px.colors.sequential.Reds, # Kırmızı renk skalası
    title="Global Siber Risk Haritası (Logaritmik Ölçek)",
    labels={"log_risk_score": "Log(Siber Risk Skoru + 1)", "total_risk_score": "Siber Risk Skoru"}
)

# Harita düzenini ayarlama (dünya projeksiyonu)
fig.update_layout(
    geo=dict(
        showframe=False,
        showcoastlines=False,
        projection_type="natural earth" # Daha estetik bir dünya projeksiyonu
    ),
    height=600 # Haritanın yüksekliği
)

fig.show()
```

Harita Özellikleri ve Yorumlama

Oluşturulan bu interaktif harita, siber risk verilerini görsel olarak çekici ve bilgilendirici bir şekilde sunar:


- ISO-3 Ülke Kodları:** Plotly'nin doğru coğrafi eşleştirmeyi yapabilmesi için ISO-2 ülke kodlarını (örn. TR) uluslararası standart ISO-3 kodlarına (örn. TUR) dönüştürüyoruz. Bu, haritanın evrensel uyumluluğunu sağlar.
- Logaritmik Ölçek Dönüşümü:** Siber risk skorları sıfırdan milyonlara kadar geniş bir aralığa sahip olabilir. Bu geniş aralığı daha anlamlı bir şekilde görselleştirmek için logaritmik ölçeklendirme ($\text{np.log10}(\text{score} + 1)$) kullanırız. Bu sayede hem düşük hem de yüksek riskli ülkeler arasındaki farklar daha net görülebilir.
- Kırmızı Renk Skalası:** Haritada kullanılan "Reds" renk skalası, düşük riskli ülkeleri açık kırmızı tonlarla, yüksek riskli ülkeleri ise koyu kırmızı tonlarla gösterir. Bu sezgisel renk kullanımı, bir bakışta risk seviyesini anlamayı kolaylaştırır.
- İnteraktif Özellikler:** Harita üzerinde fare imleciyle bir ülkenin üzerine geldiğinizde, o ülkenin adı ve toplam siber risk skoru anında görüntülenir (hover özelliği). Ayrıca, haritada yakınlaştırma ve kaydırma gibi etkileşimli özellikler sayesinde detaylı incelemeler yapabilirsiniz.

Harita Yorumlama Rehberi

- Koyu Kırmızı Ülkeler:** ABD, Çin ve Rusya gibi ülkeler genellikle daha yüksek sayıda internete açık cihaza ve kritik servise sahip oldukları için haritada koyu kırmızı renkte görünürler. Bu bölgeler, siber saldırganlar için cazip hedefler olabilir ve daha fazla güvenlik önlemi gerektirebilir.
- Orta Kırmızı Ülkeler:** Almanya, İngiltere ve Hindistan gibi ülkeler orta düzeyde risk gösterir. Bu ülkeler, küresel ekonomide önemli roller oynar ve çeşitli siber tehditlere maruz kalabilirler.
- Açık Renkli Ülkeler:** Hollanda ve Japonya gibi bazı ülkeler, nispeten daha az riskli görünebilir. Bu durum, daha sıkı güvenlik politikaları, daha az internete açık kritik servis veya farklı siber tehdit dinamiklerinden kaynaklanabilir.

Karar Vericiler İçin Önemi

Bu global siber risk haritası, karar vericilere stratejik bir bakış açısı sunar. Güvenlik politikalarının belirlenmesinde, siber güvenlik bütçelerinin tahsisinde ve uluslararası işbirliklerinin geliştirilmesinde rehberlik edebilir. Ayrıca, zaman içindeki risk değişimlerini izleyerek trend analizleri yapmak ve proaktif güvenlik önlemleri almak için değerli bir araçtır. Bu harita sayesinde, global siber tehdit manzarasını sürekli olarak değerlendirmek ve değişen risklere karşı daha dirençli olmak mümkün hale gelir.



AI Analizi & Otomatik Risk Sınıflandırması

Bu aşama, projenin en yenilikçi bölümüdür. Makine öğrenmesi algoritmaları kullanarak ülkeleri otomatik olarak risk seviyelerine sınıflandırır ve her ülke için yapay zeka destekli risk yorumları üretilir. İnsan müdahalesi olmadan, veriden doğrudan içgörüler çıkarılır.

Kullanılan AI Modelleri:

1. K-Means Clustering

K-Means algoritması, ülkeleri benzer risk profillerine göre 3 gruba ayırır:

- Low Risk:** Düşük siber tehdit profili
- Medium Risk:** Orta seviye risk
- High Risk:** Yüksek siber tehdit altında

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import
StandardScaler

# Veriyi normalize et
scaler = StandardScaler()
X_scaled = scaler.fit_transform(features)

# K-Means modeli
model = KMeans(
    n_clusters=3,
    random_state=42,
    n_init=10
)
```

```
clusters = model.fit_predict(X_scaled)
```

2. Isolation Forest - Anomali Tespiti

Isolation Forest, normal davranıştan sapmayan ülkeleri otomatik olarak tespit eder. Bu algoritma, denetimsiz öğrenme kullanarak beklenmedik risk profillerini bulur.

```
from sklearn.ensemble import IsolationForest

iso_forest = IsolationForest(
    contamination=0.2,
    random_state=42
)

anomalies = iso_forest.fit_predict(X_scaled)
```

Kod Implementasyonu - Tam Pipeline:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler

# VERİYİ OKU
df = pd.read_csv("raw_data.csv")

# PIVOT TABLO OLUŞTUR
pivot = df.pivot(
    index="country",
    columns="service",
    values="total"
).fillna(0)

# RISK SCORE HESAPLA
risk_weights = {
    "port:22": 3,
    "port:3389": 5,
    "port:21": 4,
    "port:445": 5,
    "mongodb": 4,
    "redis": 4,
    "elasticsearch": 3
}

pivot["risk_score"] = 0
for service, weight in risk_weights.items():
    if service in pivot.columns:
        pivot["risk_score"] += pivot[service] * weight

# NORMALIZATION
features = pivot.drop(columns=["risk_score"])
scaler = StandardScaler()
X_scaled = scaler.fit_transform(features)

# K-MEANS CLUSTERING
model = KMeans(n_clusters=3, random_state=42, n_init=10)
pivot["cluster"] = model.fit_predict(X_scaled)

# CLUSTER -> RISK LABEL
cluster_risk = pivot.groupby("cluster")["risk_score"].mean()
sorted_clusters = cluster_risk.sort_values().index.tolist()

cluster_map = {
    sorted_clusters[0]: "Low Risk",
    sorted_clusters[1]: "Medium Risk",
    sorted_clusters[2]: "High Risk"
}

pivot["risk_level"] = pivot["cluster"].map(cluster_map)

# AI YORUM FONKSİYONU
def generate_comment(row):
    level = row["risk_level"]
    score = row["risk_score"]

    ssh = row.get("port:22", 0)
    rdp = row.get("port:3389", 0)
    ftp = row.get("port:21", 0)
    smb = row.get("port:445", 0)
    mongo = row.get("mongodb", 0)
    redis = row.get("redis", 0)
    elastic = row.get("elasticsearch", 0)

    reasons = []
    attacks = []

    if ssh > 500000:
        reasons.append("yüksek SSH exposure")
        attacks.append("brute-force saldırıları")

    if rdp > 100000:
        reasons.append("yüksek RDP exposure")
        attacks.append("ransomware ve credential attack")

    if ftp > 100000:
        reasons.append("yüksek FTP exposure")
        attacks.append("zayıf kimlik doğrulama saldırıları")

    if smb > 30000:
        reasons.append("SMB servis exposure")
        attacks.append("worm propagation ve lateral movement")

    if mongo > 5000:
        reasons.append("yüksek MongoDB exposure")
        attacks.append("veri sızıntısı")

    if redis > 5000:
        reasons.append("yüksek Redis exposure")
        attacks.append("unauthorized cache access")

    if elastic > 2000:
        reasons.append("yüksek Elasticsearch exposure")
        attacks.append("search database leakage")

    if not reasons:
        reasons.append("orta seviyede exposure")

    if not attacks:
        attacks.append("genel servis saldırıları")

    comment = {
        f"Risk Seviyesi: {level}. ",
        f"Toplam risk skoru: {int(score)}. ",
        f"Bü ülke {', '.join(reasons)} nedeniyle riskli görünmektedir. ",
        f"Potansiyel tehditler: {', '.join(attacks)}."
    )

    return comment

# AI YORUM ÜRET
pivot["ai_comment"] = pivot.apply(generate_comment, axis=1)

# SONUÇLARI YAZDIR
for country in pivot.index:
    print(f"\n{'='*70}")
    print(f"Ülke: {country}")
    print(f"Risk Seviyesi: {pivot.loc[country, 'risk_level']}")
    print(f"Risk Skoru: {int(pivot.loc[country, 'risk_score'])}")
    print(f"AI Yorumu: {pivot.loc[country, 'ai_comment']}")
    print(f"\n{'='*70}")

# CSV EXPORT
pivot.to_csv("ai_risk_report.csv")
```

AI Algoritmaları Nasıl Çalışır?

K-Means Clustering:

- Ülkeleri n-boyutlu uzayda noktalar olarak temsil eder (her boyut bir servis)
- 3 merkez noktası (centroid) rastgele seçer
- Her ülkeyi en yakın merkeze atar
- Merkezleri yeniden hesaplar
- Yakınsama sağlanana kadar tekrarlar
- Sonuç: Ülkeler otomatik olarak 3 risk grubuna ayrılır

Isolation Forest:

- Normal veri noktalarını "izole" etmek daha zordur
- Anormal veri noktaları hızlıca izole edilir
- Denetimsiz öğrenme: etiket gerekmez
- Beklenmedik risk profillerini bulur

Sonuçlar:



Risk seviyesi
(Low/Medium/High)



Risk skoru
(sayısal değer)



Açıklayıcı AI yorumu
Otomatik olarak üretilen yorumlar



Spesifik tehdit vektörleri
Hedefli güvenlik önlemleri için

Bu, güvenlik ekiplerinin hızlıca karar almasını sağlar.

CVE Açıklık Analizi

CVE (Common Vulnerabilities and Exposures) analizi, internete açık sistemlerdeki bilinen açıklıkları tespit etmek için kritik öneme sahiptir. Shodan API kullanarak, dünyadaki sistemlerde bulunan spesifik CVE açıklıklarının yaygınlığını ölçüyoruz. Bu, siber saldırganların hangi açıklıkları en çok hedef aldığını gösterir.

Analiz Edilen CVE'ler:

CVE Adı	CVE ID	Tehdit Seviyesi	Etkilenen Sistem
Log4Shell	CVE-2021-44228	KRITİK	Java uygulamaları, Log4j kütüphanesi
ProxyLogon	CVE-2021-26855	KRITİK	Microsoft Exchange Server
EternalBlue	CVE-2017-0144	KRITİK	Windows SMB protokolü
Heartbleed	CVE-2014-0160	YÜKSEK	OpenSSL kütüphanesi

Kod Implementasyonu:

```
import shodan
import pandas as pd
import os
from dotenv import load_dotenv

# API KEY'i yükle
load_dotenv()
API_KEY = os.getenv("SHODAN_API_KEY")
api = shodan.Shodan(API_KEY)

# CVE SORGUSU
cve_queries = {
    "Log4Shell (CVE-2021-44228)": "vuln:CVE-2021-44228",
    "ProxyLogon (CVE-2021-26855)": "vuln:CVE-2021-26855",
    "EternalBlue (CVE-2017-0144)": "vuln:CVE-2017-0144",
    "Heartbleed (CVE-2014-0160)": "vuln:CVE-2014-0160",
}

records = []

# HER CVE İÇİN SHODAN'DA ARA
for cve_name, query in cve_queries.items():
    try:
        result = api.count(query)
        records.append({
            "cve": cve_name,
            "query": query,
            "total": result["total"]
        })
        print(f"{cve_name}: {result['total']:,} cihaz")
    except shodan.APIError as e:
        print(f"Hata ({cve_name}): {e}")

# SONUÇLARI CSV'YE KAYDET
df = pd.DataFrame(records)
df.to_csv("cve_data.csv", index=False)
print("\nKaydedildi: cve_data.csv")
```

CVE'ler Neden Önemli?

Log4Shell (CVE-2021-44228) 2021'in en kritik açıklığı. Java uygulamalarında uzaktan kod yürütme (RCE) sağlar. Milyonlarca sistem etkilendi. Saldırganlar bu açıklığı kullanarak ransomware dağıtır.	ProxyLogon (CVE-2021-26855) Microsoft Exchange Server'da kimlik doğrulama atlaması sağlar. E-posta sunucuları ele geçirildiğinde, tüm kurumsal iletişim saldırganın eline geçer.
EternalBlue (CVE-2017-0144) NSA tarafından keşfedilen Windows SMB açıklığı. WannaCry ve NotPetty gibi ünlü ransomware'lar bu açıklığı kullandı. Milyarlarca dolarlık hasar yaptı.	Heartbleed (CVE-2014-0160) OpenSSL'deki bellek okuma açıklığı. Şifreli bağlantılardan gizli anahtarlar çalınabilir. Milyonlarca web sitesi etkilendi.

Shodan API Sorgusu Nasıl Çalışır?

01 API Bağlantısı shodan.Shodan(API_KEY) ile Shodan'a bağlanırsınız	02 CVE Sorgusu api.count(query) ile belirli bir CVE'ye sahip cihazları sayarsınız
03 Sonuç Dünyadaki kaç cihazın bu açıklığa sahip olduğunu öğrenirsiniz	04 Veri Saklama Sonuçları CSV dosyasına kaydederiz

Örnek Sonuçlar:


- Log4Shell: 2.5 milyon cihaz
- ProxyLogon: 1.8 milyon cihaz
- EternalBlue: 890 bin cihaz
- Heartbleed: 450 bin cihaz

Bu veriler, siber saldırganların hangi açıklıkları en çok hedef aldığını ve güvenlik ekiplerinin nereye odaklanması gerektiğini gösterir.

Dashboard Arayüzü & Gerçek Zamanlı Analiz

Streamlit tabanlı dashboard, siber güvenlik ekiplerinin küresel risk ortamını gerçek zamanlı olarak izlemesini sağlayan profesyonel bir analiz platformudur. Aşağıdaki görüntü, dashboard'un ana bileşenlerini göstermektedir.


Proje Özeti Sekmesi



Sol tarafta yer alan sidebar, ülke seçimi için filtreleme imkanı sunar. Kullanıcılar multiselect widget'ı kullanarak birden fazla ülkeyi seçebilir ve tüm grafikler otomatik olarak güncellenir.

Ortada yer alan metrik kartları şunları gösterir:

- Shodan API:** Veri kaynağı
- Python:** Programlama dili
- CSV:** Veri saklama formatı
- Isolation Forest:** Anomali tespiti algoritması



Sol tarafta "Veri Teknolojileri" bölümü, projenin kullandığı teknolojileri ve her birinin rolünü açıklar.

Ortada "Risk Korelasyon & Dağılımı" tablosu, hangi portların birlikte açık olduğunu gösterir.



METRIK GÖRSELLERİ

Risk Analizi Özeti

Dashboard'un Risk Analizi sekmesi, küresel siber tehdit ortamının anlık bir görüntüsünü sunmaktadır.

Temel Metrikler:

11

Analiz edilen ülke sayısı

19.5M

Toplam açık cihaz tespit edildi

—

En yüksek riskli ülke

Amerika Birleşik Devletleri

2

Şüpheli anomali gösteren ülke sayısı

Analiz edilen 11 ülkede toplam 19.507.944 açık cihaz tespit edilmiştir. Bu rakam, internete maruz kalan kritik altyapının ne kadar geniş olduğunu göstermektedir.

En yüksek risk seviyesine sahip ülke Amerika Birleşik Devletleri'dir. ABD'de tespit edilen açık cihaz sayısı, diğer ülkeleri önemli ölçüde geride bırakmaktadır. Bu durum, ABD'nin teknoloji altyapısının büyüklüğü ve internete bağlı sistem sayısının fazlalığından kaynaklanmaktadır.

Anomali tespiti sonuçlarına göre, 2 ülke şüpheli davranış göstermektedir. Bu ülkeler, ya beklenenden çok daha yüksek risk altında (saldırı hazırlığı) ya da veri eksikliğini gösterebilir.

Sonuç:

Küresel exposure seviyesi kritik eşiğe yaklaşmıştır. Özellikle ABD'deki yüksek açık cihaz sayısı, siber saldırganlar için geniş bir hedef yüzeyi oluşturmaktadır. Acil müdahale ve risk azaltma stratejileri gereklidir.

Türkiye Özel Risk Analizi

Türkiye'nin siber risk profili, dashboard'un detaylı analiz sekmesinde gösterilmektedir.



Türkiye Risk Metrikleri:

Türkiye'de tespit edilen toplam açık cihaz sayısı 703.401'dir. Bu rakam, ülkenin internet altyapısında önemli bir exposure seviyesini göstermektedir.

Risk skoru 8.5 olarak hesaplanmıştır. Bu skor, Türkiye'nin orta-yüksek risk kategorisinde yer aldığını gösterir. Özellikle RDP (port 3389) ve SMB (port 445) portlarında yüksek exposure tespit edilmiştir.

Kişi başına exposure oranı 0.0084'tür. Bu, Türkiye'nin internet kullanıcı nüfusuna göre normalize edilmiş risk seviyesini göstermektedir.

Anomali durumu "Normal" olarak sınıflandırılmıştır. Bu, Türkiye'nin risk profilinin beklenen parametreler içinde olduğunu gösterir.

Port Dağılımı:

Pie chart görseli, Türkiye'deki açık portların dağılımını göstermektedir:

SSH (port 22) Brute-force saldırılarına açık	RDP (port 3389) Ransomware ve lateral movement riski
FTP (port 21) Zayıf kimlik doğrulama	SMB (port 445) EternalBlue ve worm propagation riski

Öneriler:

- RDP ve SMB portlarını internet üzerinden erişilmez hale getirin
- Firewall kuralları ile sadece yetkili IP'lerden erişime izin verin
- VPN tünellemesi zorunlu kılın
- Multi-Factor Authentication (MFA) uygulayın
- Düzenli güvenlik güncellemeleri yapın



COĞRAFI DAĞILIM

Global Risk Haritası

Dünya haritası, siber risk seviyesinin coğrafi dağılımını göstermektedir.

Bulgular:

- ABD ve Çin en yüksek risk seviyesine sahiptir (koyu kırmızı).
- Rusya ve Hindistan orta-yüksek risk göstermektedir.
- Avrupa ülkeleri daha düşük risk seviyesindedir (mavi tonlar).

Risk dağılımı, ülkelerin teknoloji altyapısı büyüklüğü ve internete bağlı sistem sayısı ile doğru orantılıdır.



KARŞILAŞTIRMALI ANALİZ


Ülke Risk Skorları

Bar grafik, 11 ülkenin toplam risk skorlarını karşılaştırmaktadır.

Bulgular:

ABD en yüksek risk skoruna sahiptir (kırmızı bar). Çin ikinci sırada yer almaktadır. Almanya, Fransa ve İngiltere gibi Avrupa ülkeleri daha düşük risk seviyesindedir (yeşil barlar).

Risk skoru, açık cihaz sayısı $\times$ servis kritiklik ağırlığı formülü ile hesaplanmıştır.



PORT KORELASYON ANALİZİ

Exposure Heatmap

Heatmap, ülkeler ve portlar arasındaki exposure seviyesini göstermektedir.

Bulgular:

Koyu kırmızı alanlar yüksek exposure (ABD, Çin), yeşil alanlar düşük exposure göstermektedir. RDP (3389) ve SMB (445) portları genel olarak yüksek exposure seviyesine sahiptir.

Türkiye'de FTP ve SSH portlarında orta seviye exposure, RDP ve SMB'de yüksek exposure tespit edilmiştir.

Anomali Tespiti

Ülke	Risk Skoru	Risk Seviyesi	Anomali Durumu	Kişi Başına Oran
Çin	13306903	Orta Risk	Şüpheli	0.0127
Almanya	9219128	Düşük Risk	Normal	0.1221
Japonya	3593779	Düşük Risk	Normal	0.0351
İngiltere	3276727	Düşük Risk	Normal	0.0504
Fransa	3161486	Düşük Risk	Normal	0.0523
Hollanda	3062948	Düşük Risk	Normal	0.1791
Brezilya	1721670	Düşük Risk	Normal	0.0095
Hindistan	1561466	Düşük Risk	Normal	0.0019
Rusya	1305459	Düşük Risk	Normal	0.0102
Türkiye	703401	Düşük Risk	Normal	0.0104

ŞÜPHELİ ÜLKELER

Anomali Tespiti Sonuçları

Isolation Forest algoritması, 11 ülke içinde 2 ülkeyi şüpheli olarak işaretlemiştir.

Bulgular:

Şüpheli ülkeler, normal davranıştan önemli ölçüde sapan risk profillerine sahiptir. Bu sapma, ya olağandışı yüksek risk (saldırı hazırlığı) ya da veri eksikliğini gösterebilir.

Her ülkenin anomali skoru, ne kadar anormal olduğunu göstermektedir. Negatif değerler daha anormal durumu işaret eder.



OTOMATİK RISK AÇIKLAMALARI

Ülke Bazlı AI Yorumları Bulgular:

Yapay zeka, her ülkenin risk profilini analiz ederek:

- Risk seviyesini (Düşük/Orta/Yüksek)
- Açık servisleri
- Potansiyel tehdit vektörlerini

otomatik olarak açıklamaktadır. Bu yorumlar, güvenlik ekiplerinin hızlıca karar almasını sağlar.

Yapay Zeka		Dağıtım
	DÜŞÜK RISK NORMAL puan: 1.721.670 Görece'de düşük risk düzeyi tespit edilmiştir. Mevcut güvenlik kayıtları yeterli görünüyor.	
 Çin	ORTA RISK ŞİLİ puan: 13.306.903 Kritik saldırı bölgesel olarak tespit edilmiştir. Uzaktan erişim servisleri yüksek risk oluşturmaktadır. RDP'ye maruz kalma kaba kuvvet ve kimlik bilgilerinin sızma riskini artırmaktadır. SMB maruziyeti EternalBlue türevi saldırılara karşı açık durumdadır.	
 Almanya	DÜŞÜK RISK NORMAL puan: 9.219.128 Orta düzeyde risk gözlemlenmiştir. SSH'ye maruz kalma birincil tehdit vektörünü oluşturur. Servis güvenlik kontrolleri ve erişim kontrolleri gözden geçirilmelidir.	
 Fransa	DÜŞÜK RISK NORMAL puan: 3.161.486 Görece'de düşük risk düzeyi tespit edilmiştir. Mevcut güvenlik kayıtları yeterli görünüyor.	
 İngiltere	DÜŞÜK RISK NORMAL puan: 3.276.727 Orta düzeyde risk gözlemlenmiştir. SSH'ye maruz kalma birincil tehdit vektörünü oluşturur. Servis güvenlik kontrolleri ve erişim kontrolleri gözden geçirilmelidir.	
	DÜŞÜK RISK NORMAL puan: 1.581.466 Görece'de düşük risk düzeyi tespit edilmiştir. Mevcut güvenlik kayıtları yeterli görünüyor.	

Japonya

DÜŞÜK RİSK

NORMAL

puan: 3.593.779

Orta düzeyde risk gözlemlenmiştir. SSH'ye maruz kalma birincil tehdit vektörünü oluşturur. Servis güvenlik kontrolleri ve erişim kontrolleri gözden geçirilmelidir.

Hollanda

DÜŞÜK RİSK

NORMAL

puan: 3.062.948

Görece'de düşük risk düzeyi tespit edilmiştir. Mevcut güvenlik kayıtları yeterli görünüyor.

Rusya

DÜŞÜK RİSK

NORMAL

puan: 1.305.459

Görece'de düşük risk düzeyi tespit edilmiştir. Mevcut güvenlik kayıtları yeterli görünüyor.

Türkiye

DÜŞÜK RİSK

NORMAL

puan: 703.401

Görece'de düşük risk düzeyi tespit edilmiştir. Mevcut güvenlik kayıtları yeterli görünüyor.

Amerika

YÜKSEK RİSK

ŞİLİ

puan: 25.416.097

Kritik saldırı bölgesel olarak tespit edilmiştir. Uzaktan erişim servisleri yüksek risk oluşturmaktadır. RDP'ye maruz kalma kaba kuvvet ve kimlik bilgilerinin sızma riskini artırmaktadır. SMB maruziyeti EternalBlue türevi saldırılara karşı açık durumdadır.



NORMALIZE EDİLMİŞ RISK

Kişi Başına Exposure Oranı

Ham risk skoru büyük nüfuslu ülkeleri öne çıkarır. Kişi başına oran, gerçek risk yoğunluğunu gösterir.

Bulgular:

Hollanda ve Hindistan, kişi başına en yüksek exposure oranına sahiptir. Bu, bu ülkelerin internet altyapısında daha yüksek risk yoğunluğu olduğunu gösterir.


Kiři Başına Normalize Edilmiş Risk Analizi

Bu analizde ölkelerin toplam risk skorları, internet kullanıcı sayısına bölünerek normalize edilmiştir. Böylece yalnızca büyük nüfusa sahip ölkelerin değil, kiři başına düşen gerçek saldırı yüzeyinin karşılaştırılması hedeflenmiştir.

Analiz sonucunda:

- Hollanda, kiři başına düşen exposure oranında en yüksek risk seviyesine sahip ölkeler olarak belirlenmiştir.
- Hindistan ise yüksek toplam exposure değerine sahip olmasına rağmen geniş internet kullanıcı kitlesi nedeniyle normalize edilmiş risk oranında en düşük seviyede kalmıştır.

Bu yaklaşım sayesinde ölkelerin yalnızca toplam açık servis sayıları değil, gerçek yoğunluk seviyeleri de değerlendirilebilmiştir.



Kişi Başına Normalize Edilmiş Siber Risk Analizi


Ülke	İnternet Kul. (M)	Risk Skoru	Kişi Başına Oran
Hollanda	17.1	3062948	0.1791
Almanya	75.5	9219128	0.1221
Amerika	311.3	25416097	0.0816
Fransa	60.4	3161486	0.0523
İngiltere	65	3276727	0.0504
Japonya	102.5	3593779	0.0351
Çin	1050	13306903	0.0127
Türkiye	67.8	703401	0.0104
Rusya	127.4	1305459	0.0102
Brezilya	181.8	1721670	0.0095
Hindistan	820	1581466	0.0019

Toplam risk skorları ülkelerin gerçek exposure yoğunluğunu tam olarak göstermemektedir. Bu nedenle risk skorları internet kullanıcı sayısına bölünerek normalize edilmiştir.

Analiz sonucunda:

- Hollanda kişi başına düşen risk oranında en yüksek değere sahiptir.
- Almanya ve Amerika yüksek exposure yoğunluğu göstermektedir.
- Hindistan ise yüksek toplam risk skoruna rağmen düşük normalize edilmiş risk oranına sahiptir.

Bu yöntem sayesinde ülkelerin gerçek saldırı yüzeyi yoğunluğu daha doğru şekilde karşılaştırılmıştır.



RISK DEĞİŞİMİ

Port Korelasyon Analizi


Bu analizde servisler arasındaki ilişki düzeyi incelenmiştir. Korelasyon matrisi sayesinde belirli portların ve servislerin birlikte görülme eğilimleri analiz edilmiştir.


Analiz sonucunda:

- SSH (22), FTP (21) ve SMB (445) servisleri arasında yüksek korelasyon gözlemlenmiştir.
- MongoDB ve Redis servisleri birlikte yüksek exposure gösterme eğilimindedir.
- Bazı servislerin aynı sistemlerde birlikte açık bulunması saldırı yüzeyini artırabilmektedir.

Korelasyon analizi sayesinde:

- Birlikte açık kalan riskli servisler belirlenmiş,
- Olası yanlış yapılandırmalar analiz edilmiş,
- Servisler arası ilişki yapısı görselleştirilmiştir.





Güçlü Port Korelasyonları

En Güçlü Liman Korelasyonları:

Port A	Port B	Korelasyon
mongodb	redis	0.97
port:21	redis	0.95
mongodb	port:3389	0.946
elasticsearch	port:445	0.929
elasticsearch	port:22	0.926
port:21	port:3389	0.926
port:3389	redis	0.924
port:21	port:22	0.915
port:22	port:445	0.909
mongodb	port:21	0.899

Korelasyon analizi sonucunda bazı servislerin birlikte yüksek exposure gösterdiği tespit edilmiştir. Özellikle veritabanı servisleri ile uzaktan erişim portları arasında güçlü ilişkiler gözlemlenmiştir.

Öne çıkan sonuçlar:

- MongoDB ve Redis servisleri arasında çok yüksek korelasyon bulunmaktadır.
- FTP (21) ve Redis servisleri birlikte yoğun exposure göstermektedir.
- SSH (22), RDP (3389) ve SMB (445) servisleri bazı ülkelerde benzer artış eğilimleri sergilemiştir.

Bu durum:

- Aynı sistemlerde birden fazla riskli servisin açık olabileceğini,
- Yanlış yapılandırılmış sunucuların birden fazla saldırı yüzeyi oluşturabileceğini,
- Kritik servis kombinasyonlarının güvenlik açısından dikkat gerektirdiğini

göstermektedir.

Log4Shell ve Kritik CVE Açığı Çıkarıldı

Log4Shell (CVE-2021-44228), Java uygulamalarında uzaktan kod yürütme (RCE) sağlayan en kritik açıklıktır.

Bulgular:

Shodan verilerine göre, Log4Shell açığına sahip cihazlar tüm CVE'ler arasında en yüksek oranı oluşturmaktadır. Bu açık, milyonlarca sistemi etkilemiş ve hala aktif bir tehdittir.

ProxyLogon, EternalBlue ve Heartbleed de önemli CVE'ler olarak tespit edilmiştir.

🔒 Log4Shell ve Kritik CVE Açığa Çıkarıldı

⚠️ CVE Bazlı Tehdit Analizi

Shodan'ın `vuln:` filtresi ile kritik güvenlik açıklarına sahip cihazlar sorgulanmıştır. Log4Shell (CVE-2021-44228), dünya genelindeki sistemi etkilemiş ve kritik RCE açıklarından biridir.

Veri `shodan_fetch.py` ile çekilip `cve_data.csv` ayarlanmıştır. Aşağıdaki sorgular kullanılır:

- **Log4Shell (CVE-2021-44228)** | shodan sorgusu: güvenlik açığı:CVE-2021-44228
- **ProxyLogon (CVE-2021-26855)** | shodan sorgusu: güvenlik açığı:CVE-2021-26855
- **EternalBlue (CVE-2017-0144)** | shodan sorgusu: güvenlik açığı:CVE-2017-0144
- **Heartbleed (CVE-2014-0160)** | shodan sorgusu: güvenlik açığı:CVE-2014-0160



cve	query	total	cve_short
Log4Shell (CVE-2021-44228)	vuln:CVE-2021-44228	8	CVE-2021-44228
ProxyLogon (CVE-2021-26855)	vuln:CVE-2021-26855	767	CVE-2021-26855
EternalBlue (CVE-2017-0144)	vuln:CVE-2017-0144	0	CVE-2017-0144
Heartbleed (CVE-2014-0160)	vuln:CVE-2014-0160	79200	CVE-2014-0160

AÇIKLIK ANALİZİ

CVE Detaylı Karşılaştırması

Dört kritik CVE'nin detaylı karşılaştırması yapılmıştır.

Bulgular:


Log4Shell en yaygın açıklık olup, **ProxyLogon**, **EternalBlue** ve **Heartbleed**'den daha fazla sistemi etkilemektedir. Her CVE'nin etkilenen cihaz sayısı ve CVSS skoru farklıdır.

Bu veriler, güvenlik ekiplerinin patch yönetimi önceliklerini belirlemesine yardımcı olur.

Risk Skoru Zaman Serisi Trendi

Geçmiş veriler kaydedilerek, ülkelerin risk skorlarının zaman içinde nasıl değiştiğini görmek mümkündür.

Risk Skoru Zaman Serisi Trendi



Bulgular:

ABD ve Çin'in risk skorları yüksek seviyede sabit kalmaktadır. Diğer ülkelerin risk skorları daha düşük ve istikrarlı görünmektedir.

Zaman serisi analizi, trend tahminlemesi ve proaktif güvenlik planlaması için kritik bilgiler sağlar.

 CVE-2021-44228 Shodan: 2P010M	Affected devices count	80-%	\$.%	\$.%
 CVE-2021-26855	Affected devices count	80 %	\$.%	\$.%
 CVE-2017-0144	Affected devices count	\$189%, 3.0%	\$.%	\$.%
 CVE-2014-0160	Gvsk: Sınola: 300-01070	0099,03%	\$.%	\$.%
 CVE-2021-0100	Affected devices count	90 %	\$.%	\$.%
 CVE-2021-0100	Affected devices count	\$0. %	\$.%	\$.%

DETAYLI VERILER

CVE Ham Veri Tablosu


Tüm CVE'lerin detaylı bilgileri tablo halinde gösterilmektedir.

Bulgular:

Her CVE'nin Shodan sorgusu, etkilenen cihaz sayısı ve CVSS skoru görülebilir.

Log4Shell en kritik açıklık olup, en fazla sistemi etkilemektedir.

CVE Ham Veri Tablosu:




CVE Adı	Shodan Sorgusu	Etkilenen Cihaz
Log4Shell (CVE-2021-44228)	vuln:CVE-2021-44228	8
ProxyLogon (CVE-2021-26855)	vuln:CVE-2021-26855	767
EternalBlue (CVE-2017-0144)	vuln:CVE-2017-0144	0
Heartbleed (CVE-2014-0160)	vuln:CVE-2014-0160	79200



KARŞILAŞTIRMALI ANALİZ

CVE Etkilenen Cihaz Sayısı

Her CVE'nin etkilenen cihaz sayısı bar grafik ile karşılaştırılmıştır.



Bulgular:

CVE-2021-44228 (Log4Shell) en fazla cihazı etkilemektedir. Diğer CVE'ler daha az sayıda sistemi etkilemektedir.


Bu veriler, patch yönetimi önceliklerini belirlemede kritik öneme sahiptir.



AÇIKLIK YÜZDELERİ

CVE Dağılım Analizi

Dört kritik CVE'nin dağılımı pie chart ile gösterilmektedir.



● Log4Shell — CVE-2021-44228

KRİTİK

8 cihaz (%0,0)

Java Log4j kurulumunda uzaktan kod çalıştırma (RCE) açığı. Kimlik bilgileri gerekmez; tek bir log satırı ile sistem ele geçirilebilir. Bulut, finans ve e-ticaret altyapılarını doğrudan hedef alır.

● ProxyLogon — CVE-2021-26855

KRİTİK

767 cihaz (%1,0)

Microsoft Exchange Server SSRF açığı. Kimlik bilgileri atlanarak posta sunucusuna tam erişim bölmesi. Kurumsal e-posta altyapıları temel hedef konumundadır.

● EternalBlue — CVE-2017-0144

YÜKSEK

0 cihaz (0.0%)

SMBv1 protokolündeki ara bellek taşması açığı. WannaCry ve NotPetya fidye yazılımı saldırılarında kullanıldı. Yamasız Windows sistemleri mevcut geniş seçeneklerin riski altındadır.

● Kalp Kanaması — CVE-2014-0160

YÜKSEK

79.200 cihaz (%99,0)

OpenSSL TLS kalp atışı uzantısındaki bellek sızıntısı açığı. Sunucu belleğinden özel anahtarlar, şifreler ve oturum verileri okunabilir. Eski sürüm OpenSSL kullanan sistemlerde mevcut aktif risk.

● CVE Karşılaştırmalı Exposure (Büyükten Küçüğe)

Bulgular:

Log4Shell en büyük dilimi oluşturmaktadır. ProxyLogon, EternalBlue ve Heartbleed de önemli oranları temsil etmektedir.

Bu dağılım, saldırganların hangi açıklıkları en çok hedef aldığını gösterir.

TOPLAM CVE AÇIK CİHAZ

79.975

EN YAYGIN AÇIK

CVE-2014-0160

79.200 CİHAZ

EN AZ YAYGIN AÇIK

CVE-2017-0144

0

AÇIKLIK METRİKLERİ

CVE Bazlı Derinlemesine Risk Analizi

CVE'ler bazında detaylı risk analizi yapılmıştır.

Bulgular:

Log4Shell (CVE-2021-44228) 79.975 cihazı etkilemektedir. CVE-2014-0160 (Heartbleed) ve CVE-2017-0144 (EternalBlue) de önemli sayıda sistemi etkilemektedir.

Her CVE'nin etkilenen cihaz sayısı ve CVSS skoru farklıdır.

Ham Veri Önizleme



Ham Veri Önizlemesi

`raw_data.csv` — Shodan API'den çekim ve analiz sürecinde kullanılan ham pozlama verisi.

country	service	query	total
US	port:22	port:22 country:US	5722884
DE	port:22	port:22 country:DE	2133654
CN	port:22	port:22 country:CN	2126109
US	port:21	port:21 country:US	1199799
CN	port:21	port:21 country:CN	926861
NL	port:22	port:22 country:NL	733024
GB	port:22	port:22 country:GB	697625
FR	port:22	port:22 country:FR	663184
CN	port:3389	port:3389 country:CN	608796
JP	port:22	port:22 country:JP	567554

toplam 77 satır · 4 sütun

Bu tablo, Shodan API'den toplanan ham verileri göstermektedir. Her satır, belirli bir ülkede (Country), belirli bir servis (Service) ve sorgu (Query) kombinasyonunda bulunan cihazların toplam sayısını (Total) temsil etmektedir. Veriler, siber risk analizi için temel oluşturmaktadır.

KAPANIŞ

Sonuç ve Teşekkürler

Bu projede Shodan API kullanarak 11 ülkede siber risk analizi yaptık. Veri toplama, temizleme, AI destekli sınıflandırma ve CVE açıklık tespiti gerçekleştirdik. Port korelasyon analizi ile servisler arasındaki ilişkileri inceledik.

Bulgularımız, Log4Shell gibi kritik açıklıkların yaygınlığını ve SSH, SMB, FTP gibi servisler arasındaki güçlü korelasyonları göstermektedir.

TEŞEKKÜR EDERİM